



ENDÜSTRİ MÜHENDİSLİĞİ
SEÇİLMİŞ KONULAR-2

**Benzin Fiyatlarındaki Artışın Elektrikli Araç
Satışlarına Etkisi**

Makine Öğrenmesi, XAI ve Nedensellik Analizi

Veri Kaynağı: EV Market Master Dataset (Kaggle)
8 Ülke · 9 Seri (ülke × marka) · 2019–2023 · 420 Gözlem

2025–2026 Bahar Dönemi

Feryal İlayda Şahin

İstanbul Üniversitesi-Cerrahpaşa — Endüstri Mühendisliği

İÇİNDEKİLER

1. Giriş ve Araştırma Sorusu.....	3
1.1 Değişken Yapısı.....	3
1.2 Veri Seti.....	3
2. Makine Öğrenmesi ile Tahmin.....	7
2.1 Metodoloji.....	7
2.2 Performans Sonuçları ve Karşılaştırma.....	8
2.3 Değişken Önem Sıralaması.....	8
2.4 Gerçek ve Tahmin Edilen Satışların Karşılaştırılması.....	9
3. Açıklanabilir Yapay Zekâ (SHAP Analizi).....	9
3.1 SHAP Değerleri — Değişken Önem Sıralaması.....	10
3.2 Öne Çıkan SHAP Bulguları.....	11
3.3 Genel Bulgular.....	14
4. Nedensellik Analizi (Causal Inference).....	14
4.1 Veri Hazırlığı ve Değişken Rollerinin Tanımlanması.....	14
4.2 Yöntem: Double Machine Learning (LinearDML — Ortalama Nedensel Etki).....	15
4.3 Heterojen Etkiler: Causal Forest DML.....	16
4.4 Genel Bulguların Değerlendirilmesi.....	18
5. Yorumlanabilir Nedensel Etki (Interpretable Causal Effect).....	18
5.1 Causal Forest Değişken Önemi.....	19
5.2 Seri × Yıl CATE Isı Haritası.....	20
5.3 Şarj Altyapısı ve Tüketici İlgisi ile Nedensel Etki.....	21
5.4 Politika Simülasyonu: +0.30 \$/L Artış Senaryosu.....	22
5.5 Sağlıklik Kontrolü: Logaritmik Satış Modeli.....	22
6. Genel Bulgular ve Tartışma.....	23
6.1 Makine Öğrenmesi Bulgularının Değerlendirilmesi.....	23
6.2 XAI ve SHAP Bulgularının Değerlendirilmesi.....	23
6.3 Nedensellik Analizi Bulgularının Değerlendirilmesi.....	23
6.4 Türkiye İçin Çıkarımlar.....	23
6.5 Çalışmanın Sınırlılıkları.....	23
6.6 Üç Katmanın Sentezi.....	24
6.7 Araştırma Sorusunun Yanıtı.....	24
7. Sonuç.....	24
Kullanılan Araçlar ve Kütüphaneler.....	25
Kaynakça.....	25

1. Giriş ve Araştırma Sorusu

Küresel enerji dönüşümü ve artan çevre bilincinin etkisiyle elektrikli araç (EV) pazarı son yıllarda hızlı bir büyüme sergilemektedir. Bu çalışmanın temel araştırma sorusu şudur:

"Benzin fiyatlarındaki artış, elektrikli araç satışlarını etkiliyor mu? Bu etki doğrusal mı ve hangi koşullarda gerçekleşiyor?"

Bu soruyu yanıtlamak için standart korelasyon analizinin ötesine geçen üç katmanlı bir analitik çerçeve kurulmuştur: **tahmin** (ne olacak?), **açıklama** (model neden böyle tahmin ediyor?) ve **nedensellik** (gerçekten sebep bu mu?). Çalışma, endüstri mühendisliği perspektifinden politika tasarımı katkı sunmayı hedeflemektedir.

1.1 Değişken Yapısı

Değişken Türü	Değişken	Açıklama
Outcome (Y)	units_sold	Aylık EV satış adedi
Treatment (T)	gasoline_price_usd_per_liter	Benzin fiyatı (USD/L), politika değişkeni
Confounder (X)	total_chargers_cumulative	Kümülatif şarj istasyonu sayısı
Confounder (X)	trend_electric_car	Google Trends: "electric car" araması
Confounder (X)	trend_tesla / trend_byd	Marka bazlı tüketici ilgisi
Confounder (X)	year, month, quarter	Zaman trendi ve mevsimsellik
Confounder (X)	country, brand	Ülke (8) ve marka (4); birlikte 9 seri

Tablo 1. Değişken rolleri

1.1.1 Tedavi Değişkeni Seçim Gerekçesi

Benzin fiyatı, hükümetler tarafından vergi ve sübvansiyon politikaları aracılığıyla doğrudan etkilenebilir. Bu özelliği, onu politika analizi için uygun bir tedavi değişkeni kılmaktadır. Tüketicilerin yakıt maliyetini toplam sahip olma maliyeti hesabına katarak araç seçimi yaptığı bilinmektedir; dolayısıyla davranışsal mekanizma da kuramsal olarak açıktır.

1.2 Veri Seti

Analizde Kaggle'dan elde edilen EV Market Master veri seti kullanılmıştır. Veri seti 8 ülkeyi (Çin, ABD, Almanya, Fransa, Norveç, Hollanda, Hindistan, İngiltere) ve 2019–2023 dönemini aylık frekansta kapsamaktadır. Ancak satış verisi her ülke için **ülke toplamı değildir**: Fransa, Hollanda, Hindistan ve İngiltere için ülkedeki toplam EV satışı, diğer ülkeler için ise tek bir markanın satışı yer almaktadır. Çin'de BYD ve Tesla olmak üzere iki ayrı seri bulunduğu için veri toplam **9 seriden** oluşmaktadır (Tablo 2).

Seri (ülke – marka)	Dönem	Gözlem	Ort. aylık satış
Çin – BYD	2020-01 – 2023-12	48	264,489
Çin – Tesla	2021-01 – 2023-12	36	47,322
Fransa – Tümü	2019-01 – 2023-12	60	23,198
Almanya – VW	2021-01 – 2022-12	24	23,329
Hindistan – Tümü	2019-01 – 2023-12	60	2,676
Hollanda – Tümü	2019-01 – 2023-12	60	7,610
Norveç – BYD	2022-01 – 2023-12	24	1,255
ABD – Tesla	2020-01 – 2023-12	48	89,316
İngiltere – Tümü	2019-01 – 2023-12	60	23,448

Tablo 2. Veri setindeki seriler

Önemli: Satış değerleri çeyreklik ve yıllık raporlardan aylığa bölünerek tahmin edilmiştir (frequency = monthly_est). 420 gözlemde yalnızca 77 farklı satış değeri bulunmaktadır; yani satış çoğu zaman üç ay boyunca sabit kalmaktadır. Bu durum, geçmiş satış değişkenlerinin tahmin gücünü yapay olarak artırır ve aylık değişimlerin yorumlanmasını sınırlar.

1.2.1 Hedef Değişken (units_sold) İstatistikleri

İstatistik	Değer
Gözlem sayısı	420
Ortalama	54,029
Standart sapma	111,226
Minimum	40
%25	6,105
Medyan	17,536
%75	39,778
Maksimum	648,008


Tablo 3. Hedef değişkenin tanımlayıcı istatistikleri

Ortalamanın medyandan çok yüksek olması, dağılımın sağa çarpık olduğunu ve Çin – BYD gibi yüksek hacimli serilerin ortalamayı yukarı çektiğini göstermektedir.

1.2.2 Eksik Değer Analizi

Değişken	Eksik sayı	Eksik %
units_sold_lag12	108	25.71
units_sold_yoy_growth	108	25.71
units_sold_lag3	27	6.43
fast_chargers_cumulative	24	5.71
slow_chargers_cumulative	24	5.71
total_chargers_cumulative	24	5.71
trend_ev_charging	11	2.62
trend_electric_vehicle	11	2.62
units_sold_lag1	9	2.14

Tablo 4. Eksik değerler



Şekil 1. Eksik değer oranları

Yorum: units_sold_lag12 ve units_sold_yoy_growth sütunlarındaki eksiklik, her serinin ilk 12 ayında geçmiş yıl verisi bulunmamasından kaynaklanmaktadır; bu sütunlar modele alınmamıştır. Şarj altyapısı değişkenlerindeki 24 eksik gözlemin tamamı Hindistan'ın 2019–2020 dönemine aittir.

Eksik değerler genel medyan yerine **ülke içinde zaman sırasına göre doğrusal interpolasyon** ile doldurulmuştur (başta veya sonda kalan boşluklar en yakın değerle). Kümülatif bir değişken olan şarj istasyonu sayısını tüm ülkelerin medyanıyla doldurmak, örneğin Hindistan'a Avrupa ülkelerine yakın bir değer atayacağı için uygun değildir. Gecikmeli satış değerleri ise her seri için yeniden hesaplanmış; geçmiş verisi olmayan her serinin ilk 3 ayı (27 satır) model verisinden çıkarılmıştır. Böylece makine öğrenmesi aşamasında **393 gözlem** kullanılmıştır.

1.2.3 Veri Sızıntısı Kontrolü

Veri setinde hazır gelen units_sold_rolling3 değişkeni incelendiğinde, üç aylık ortalamanın **o ayın kendi satışını da içerdigi** görülmüştür. Bu değişkenle tahmin yapmak, modele cevabın bir kısmını önceden vermek anlamına gelir (veri sızıntısı). Bu nedenle bu değişken yerine yalnızca **önceki üç ayın** ortalaması (units_sold_roll3_prev) kullanılmıştır. Gecikmeli değişkenler (lag1, lag3) her seri içinde ayrı ayrı hesaplanmış ve doğru oldukları doğrulanmıştır.


1.2.4 Aykırı Değer Analizi

Hedef değişken için 3×IQR yöntemiyle **36** aykırı değer bulunmuştur (27'si Çin – BYD, 9'u ABD – Tesla serisine aittir). Bu değerler gerçek pazar büyüklüğünü yansıttığı için silinmemiştir.

1.2.5 Hedef Değişkenle Korelasyon

Değişken	units_sold ile korelasyon
Satış (1 ay önce)	+0.983
Satış (önceki 3 ay ort.)	+0.975
Satış (3 ay önce)	+0.951
Şarj Altyapısı	+0.656
Trend: BYD	+0.496
Yıl	+0.303
Marka	+0.227
Trend: Tesla	+0.201
Çeyrek	+0.074
Ay	+0.071
Trend: electric car	-0.155
Trend: ev charging	-0.168
Benzin Fiyatı (USD/L)	-0.226
Ülke	-0.295

Tablo 5. Hedef değişkenle korelasyonlar (model verisi, 393 gözlem)



Şekil 2. Değişkenler arası korelasyon matrisi

Yorum: Geçmiş satış değişkenleri hedefle çok yüksek korelasyon göstermektedir ($r \approx 0.95-0.98$); bu, zaman serisi yapısının ve satışların çeyrek boyunca sabit kalmasının doğal sonucudur. Benzin fiyatının satışlarla korelasyonu **zayıf ve negatiftir** ($r = -0.226$). Bu basit korelasyon nedensel bir sonuç değildir;

benzin fiyatı yüksek olan Avrupa ülkelerinde serilerin hacmi Çin ve ABD serilerinden düşük olduğu için ülke farkları korelasyona karışmaktadır. Bu nedenle 4. bölümde nedensellik yöntemleri kullanılmıştır.

2. Makine Öğrenmesi ile Tahmin

Bu aşamada EV satışlarını tahmin eden üç ağaç tabanlı model (Random Forest, XGBoost, LightGBM) kurulmuş ve basit bir kıyas modeliyle karşılaştırılmıştır.

2.1 Metodoloji

2.1.1 Veri Bölme

Veri ülke ve marka sırasına göre dizili olduğu için satırların son %20'sini test seti olarak ayırmak, son ayları değil son ülkeleri test etmek anlamına gelir. Bu nedenle bölme **tarihe göre** yapılmıştır: **2019–2022 dönemi eğitim (297 gözlem), 2023 yılı test (96 gözlem)**. Test seti, 2023'te verisi bulunan 8 serinin tamamını içermektedir (Almanya – VW serisi 2022'de bittiği için yalnızca eğitimde yer alır). Böylece model hiçbir zaman gelecekteki veriyi görmemekte ve gerçek kullanım koşullarına benzer biçimde değerlendirilmektedir.

2.1.2 Kullanılan Modeller ve Kıyas Modeli

Model	Temel parametreler
Random Forest	n_estimators=200, max_depth=10, min_samples_split=5, min_samples_leaf=2
XGBoost	n_estimators=300, max_depth=6, learning_rate=0.05, subsample=0.8, colsample_bytree=0.8
LightGBM	n_estimators=300, max_depth=6, learning_rate=0.05, subsample=0.8, colsample_bytree=0.8
Naif kıyas modeli	Bu ayın satışı = geçen ayın satışı (öğrenme yok)

Tablo 6. Modeller ve parametreleri

Tüm modellerde rastgelelik random_state=42 ile sabitlenmiştir. Küçük öğrenme oranı (0.05) ve sınırlı ağaç derinliği, aşırı öğrenmeyi azaltmak amacıyla seçilmiştir. **Naif kıyas modeli**, modellerin geçmiş satışı tekrarlayanın ötesinde bir şey öğrenip öğrenmediğini görmek için eklenmiştir.

Kullanılan değişkenler: benzin fiyatı, şarj altyapısı, dört arama trendi (electric car, ev charging, Tesla, BYD), satış gecikmeleri (1 ay, 3 ay, önceki 3 ay ortalaması), yıl, ay, çeyrek, ülke ve marka (toplam 14 değişken).

2.1.3 Zaman Bazlı Doğrulama

Test setine dokunmadan önce, eğitim verisi içinde ileriye doğru doğrulama yapılmıştır: önce 2020 sonuna kadarki veriyle 2021, ardından 2021 sonuna kadarki veriyle 2022 tahmin edilmiştir.

Model	R ² (2021)	R ² (2022)	Ortalama
Random Forest	0.318	0.519	0.418
XGBoost	0.348	0.568	0.458
LightGBM	-0.003	0.300	0.148


Tablo 7. Zaman bazlı doğrulama sonuçları

Doğrulama skorlarının test skorlarından belirgin biçimde düşük olması, eğitim verisi az olduğunda (özellikle 2021 tahmininde) modellerin zorlandığını ve performansın döneme göre değiştiğini göstermektedir.

2.2 Performans Sonuçları ve Karşılaştırma

Model	R ²	RMSE	MAE	MAPE
Naif (geçen ay)	0.9675	30,681	6,916	%6.42
Random Forest	0.9655	31,633	15,085	%14.67
XGBoost	0.9427	40,744	16,593	%23.79
LightGBM	0.8425	67,565	35,869	%83.47

Tablo 8. Test seti (2023) performans karşılaştırması




Şekil 3. Model performans karşılaştırması (gri: naif kıyas modeli)

Yorum: Makine öğrenmesi modelleri arasında en iyi sonucu **Random Forest** vermiştir ($R^2 = 0.9655$, MAPE = %14.67). XGBoost ikinci ($R^2 = 0.9427$), LightGBM üçüncü ($R^2 = 0.8425$) sırada yer almıştır.

Ancak dikkat çekici bulgu şudur: **"bu ay geçen ayla aynı olur" diyen naif kıyas modeli, $R^2 = 0.9675$ ve MAPE = %6.42 ile tüm modellerden daha iyi veya onlara eşit performans göstermiştir.** Bunun temel nedeni, satış verisinin çeyreklik değerlerden aylığa bölünmüş olmasıdır: satış çoğu ay bir önceki ayla aynıdır. Dolayısıyla yüksek R^2 değerleri, modellerin benzin fiyatı veya şarj altyapısından anlamlı bir örüntü öğrendiğini değil, büyük ölçüde geçmiş satışı tekrar ettiğini göstermektedir. Bu sonuç, aylık tahmin için daha ayrıntılı (gerçek aylık) veri gerektiğine işaret etmektedir.

2.3 Değişken Önem Sıralaması




Şekil 4. Üç modelin değişken önem sıralaması (kırmızı: benzin fiyatı)

Model	En önemli üç değişken	Benzin fiyatının sırası
Random Forest	Satış (3 ay önce) (%36.1), Satış (önceki 3 ay ort.) (%30.5), Satış (1 ay önce) (%29.9)	6. (%0.8)
XGBoost	Satış (1 ay önce) (%49.5), Satış (3 ay önce) (%37), Satış (önceki 3 ay ort.) (%11.5)	4. (%0.7)
LightGBM	Satış (1 ay önce) (%14.4), Trend: BYD (%13), Satış (3 ay önce) (%10.7)	8. (%6.9)

Tablo 9. Değişken önemi özeti

Üç modelde de tahminler büyük ölçüde geçmiş satış değişkenlerine dayanmaktadır (Random Forest ve XGBoost'ta toplam payları %95'in üzerindedir). Benzin fiyatının önem payı Random Forest'ta %0.8, XGBoost'ta %0.7 düzeyindedir. LightGBM'de payın daha yüksek görünmesi (%6.9), bu modelin önem ölçüsünün bölünme sayısına dayanmasından kaynaklanır ve en zayıf model olduğu için ağırlıklı yorumlanmamalıdır.

2.4 Gerçek ve Tahmin Edilen Satışların Karşılaştırılması



Şekil 5. Gerçek ve tahmin edilen satışlar (2023 test seti)

Seri	Ort. gerçek satış	MAE	MAPE
Çin – BYD	526,859	79,552	%15.8
Çin – Tesla	46,934	13,254	%33.3
Fransa – Tümü	39,704	6,893	%17.4
Hindistan – Tümü	7,536	598	%7.9
Hollanda – Tümü	8,824	419	%4.7
Norveç – BYD	2,133	414	%18.9
ABD – Tesla	156,127	15,946	%10.3
İngiltere – Tümü	40,000	3,606	%9.0

Tablo 10. Random Forest — seri bazında test hataları (2023)

Mutlak hata en çok Çin – BYD serisinde ($MAE \approx 79,552$) görülmektedir; bu seri 2023'te ortalama 527 bin adetle diğer serilerden çok büyüktür ve eğitim döneminde hiç görülmemiş seviyelere ulaşmıştır. Ağaç tabanlı modeller eğitimde gördükleri değer aralığının dışına çıkamadığı için hızlı büyüyen serilerde tahminleri gerçeğin altında kalmaktadır. Yüzdesel hata ise en yüksek Çin – Tesla (%33.3) ve Norveç – BYD (%18.9) serilerindedir.

3. Açıklanabilir Yapay Zekâ (SHAP Analizi)

Makine öğrenmesi modelleri güçlü tahmin araçları olsa da "kara kutu" yapıları karar süreçlerini gizler. SHAP (SHapley Additive exPlanations) yöntemi, her değişkenin her tahmine katkısını oyun teorisi


temelli Shapley değerleriyle hesaplayarak modeli yorumlanabilir kılar. Analiz, en iyi makine öğrenmesi modeli olan **Random Forest** üzerinde, 2023 test gözlemleri için yapılmıştır.

SHAP, modelin **neye dayanarak** tahmin yaptığını açıklar; değişkenin satışı **gerçekten etkileyip etkilemediğini** göstermez. Nedensel sorular 4. bölümde ele alınmıştır.

3.1 SHAP Değerleri — Değişken Önem Sıralaması

Sıra	Değişken	Ortalama SHAP	Yön
1	Satış (1 ay önce)	32,567	Pozitif
2	Satış (3 ay önce)	31,817	Pozitif
3	Satış (önceki 3 ay ort.)	30,110	Pozitif
4	Çeyrek	1,426	Pozitif
5	Ay	1,344	Pozitif
6	Benzin Fiyatı (USD/L)	1,138	Negatif
7	Şarj Altyapısı	716	Pozitif
8	Trend: BYD	553	Pozitif
9	Trend: ev charging	316	Zayıf / karma

Tablo 11. SHAP değişken önemi (ilk 9 değişken, birim)




Şekil 6. SHAP değişken önemi (kırmızı: benzin fiyatı)

Yorum: Geçmiş satış değişkenleri (1 ay önce, 3 ay önce, önceki 3 ay ortalaması) her biri yaklaşık 30 bin birimlik ortalama katkıyla açık ara en önemli değişkenlerdir. Benzin fiyatı 6. sırada yer almakta (ortalama |SHAP| $\approx$ 1,138 birim), yani tahmine katkısı geçmiş satışların yaklaşık otuzda biri kadardır. Ay ve çeyrek değişkenlerinin benzin fiyatından önde gelmesi, satışlardaki mevsimsel (özellikle yıl sonu) artışı yansıtmaktadır.

Geçmiş satış değişkenlerinin bu kadar baskın olması beklenen bir sonuçtur, ancak bu durum dışsal değişkenlerin etkisini model içinde gölgelemektedir. Benzin fiyatının etkisini doğru ölçmek için tahmin modelinin önem sıralaması yerine 4. bölümdeki nedensellik yöntemleri kullanılmıştır.

3.2 Öne Çıkan SHAP Bulguları


3.2.1 SHAP Summary Plot



Şekil 7. SHAP summary plot (renk: değişkenin değeri, kırmızı = yüksek)

Summary plot'ta geçmiş satış değişkenlerinde kırmızı noktaların sağda toplanması, geçmiş satış yüksek olduğunda modelin tahmini de yükselttiğini göstermektedir (momentum etkisi). Benzin fiyatının SHAP değerleri sıfıra yakın ve dar bir aralıkta dağılmaktadır; bu, benzin fiyatının model tahmini üzerindeki etkisinin sınırlı olduğunu doğrular.

3.2.2 Dependence Plot: Benzin Fiyatı (Ana Tedavi Değişkeni)




Şekil 8. Benzin fiyatı dependence plot (renk: şarj altyapısı)

Grafikte x eksenini benzin fiyatını, y eksenini bu değerin tahmine katkısını (SHAP), renk ise şarj altyapısını göstermektedir. Benzin fiyatı ile SHAP değeri arasındaki korelasyon $r = -0.27$ olup **negatiftir**: model, düşük benzin fiyatlı gözlemlerde (Çin, ABD, Hindistan) tahmini hafifçe yükseltmekte, yüksek benzin fiyatlı gözlemlerde (Avrupa) hafifçe düşürmektedir. Bu, "benzin pahalandıkça EV satışı artar" hipotezini **desteklememektedir**.

Şarj altyapısı yüksek gözlemlerde benzin fiyatının ortalama SHAP katkısı 772 birim, düşük olanlarda 25 birimdir. Ancak şarj altyapısı yüksek gözlemler büyük ölçüde Çin ve ABD serilerine aittir; bu fark bir etkileşimden çok, bu serilerin hem düşük benzin fiyatına hem de yüksek satış hacmine sahip olmasından kaynaklanıyor olabilir. Bu nedenle grafikten "şarj altyapısı benzin fiyatı etkisini güçlendiriyor" sonucu çıkarılamaz.


3.2.3 Dependence Plot: Tüketici Trendi




Şekil 9. Arama trendleri dependence plot

"electric car" arama trendinin SHAP değerleri sıfıra çok yakındır (ortalama $|SHAP| \approx 229$ birim, son sıralarda); dolayısıyla genel tüketici ilgisinin bu modelin tahminlerine katkısı çok sınırlıdır. "Tesla" trendinde ise yüksek değerlerde SHAP'ın hafifçe negatife döndüğü görülmektedir; bu da trend verisinin markaya ve ülkeye göre farklı anlam taşıdığını düşündürmektedir.

3.2.4 Waterfall Plot



Şekil 10. Waterfall: en yüksek satış gözlemi (Çin – BYD, 2023-10)



Şekil 11. Waterfall: medyan satış gözlemi (Fransa – Tümü, 2023-09)


$E[f(X)] = 41,910$, modelin eğitim verisindeki ortalama tahminidir; her çubuk, ilgili değişkenin tahmini bu değerden ne kadar uzaklaştırdığını gösterir.

Şekil 10 (Çin – BYD, 2023-10): Gerçek satış 648,008, tahmin 548,468. Tahminin neredeyse tamamı geçmiş satış değişkenlerinden gelmektedir (3 ay önceki satış +193,832, önceki 3 ay ortalaması +152,032, 1 ay önceki satış +133,289). Benzin fiyatı 1.05 \$/L ile küçük bir **pozitif** katkı (+4,353) yapmaktadır. Model, eğitimde görmediği bu yüksek seviyeyi yaklaşık 100 bin adet eksik tahmin etmiştir.

Şekil 11 (Fransa – Tümü, 2023-09): Gerçek satış 39,704, tahmin 46,950. Burada da geçmiş satışlar belirleyicidir; benzin fiyatı 1.85 \$/L ile küçük bir **negatif** katkı (-322) yapmaktadır. İki gözlem birlikte,

modelin düşük benzin fiyatını yüksek satışla ilişkilendirdiğini, yani 3.2.2'deki bulguyu tekrar göstermektedir.

3.2.5 SHAP Isı Haritası



Şekil 12. SHAP ısı haritası (2023 test gözlemleri, soldan sağa zaman sırası)

Isı haritasında sütunlar 2023'ün aylarına göre sıralanmış test gözlemleridir. Geçmiş satış değişkenlerinde güçlü kırmızı ve mavi bölgeler, büyük ve küçük serilerin tahmine farklı yönde katkısını yansıtmaktadır. Benzin fiyatının ortalama SHAP katkısı yıl içinde Ocak'taki 473 birimden Aralık'taki 301 birime gerilemiştir; ancak bu değerler çok küçük olduğundan zaman içinde belirgin bir değişim olarak yorumlanmamalıdır. Test seti yalnızca 2023'ü kapsadığı için bu grafik çok yıllık bir trend göstermez.

3.3 Genel Bulgular

- Geçmiş satış değişkenleri tahminlerin belirleyicisidir; bu durum veri yapısından (çeyreklik değerlerin aylığa bölünmesi) da kaynaklanmaktadır.
- Benzin fiyatı SHAP sıralamasında 6. sıradadır ve tahmine katkısı sınırlıdır. Katkının yönü negatiftir: model düşük benzin fiyatını yüksek satışla ilişkilendirmektedir. Bu, ülkeler arası farkı yansıtan bir ilişki olup nedensel bir yorum taşımaz.
- Arama trendleri ve şarj altyapısı modele düşük düzeyde katkı sağlamaktadır.
- SHAP bulguları, benzin fiyatının etkisini ölçmek için tahmin modelinin yeterli olmadığını, nedensellik analizine ihtiyaç duyulduğunu göstermektedir.

4. Nedensellik Analizi (Causal Inference)

Bu bölümde benzin fiyatlarının EV satışlarına nedensel etkisi Double Machine Learning (LinearDML) ve Causal Forest DML yöntemleriyle incelenmiştir. Analizde gecikmeli satış değişkenleri kullanılmadığı için 420 gözlemin tamamı kullanılmıştır.

4.1 Veri Hazırlığı ve Değişken Rollerinin Tanımlanması

- **Y – Outcome (çıktı):** units_sold (aylık EV satış adedi).
- **T – Treatment (tedavi):** gasoline_price_usd_per_liter (benzin fiyatı, USD/L).
- **X – Confounders (karıştırıcılar):** şarj altyapısı, "electric car", "Tesla" ve "BYD" arama trendleri, yıl, ay, çeyrek, ülke ve marka (9 değişken).

Etki birimi: **benzin fiyatındaki 1 USD/L artışın aylık satışa etkisi (adet)**. Örneğin ortalama fiyat 1.38 USD/L olduğundan, 0.30 USD/L artış yaklaşık %22'lik bir fiyat artışına karşılık gelir.

4.1.1 Tedavi Değişkeni ve Confounder Seçim Gerekçesi

Tedavi değişkeni olarak benzin fiyatı seçilmiştir; çünkü hükümetler vergi ve sübvansiyon yoluyla benzin fiyatına doğrudan müdahale edebilir, tüketiciler benzin maliyetini hesaba katarak EV ile içten yanmalı araç arasında seçim yapar ve ters yönlü etki (EV satışlarının benzin fiyatını belirlemesi) bu ölçekte zayıftır.


Şarj altyapısı, tüketici ilgisi, zaman, ülke ve marka değişkenleri hem benzin fiyatıyla hem de EV satışlarıyla ilişkili olabilir. Modele dahil edilmezlerse sahte korelasyon riski doğar. Korelasyon nedensellik değildir: EV satışları ve benzin fiyatı aynı dönemde artmış olabilir, ancak her ikisini de etkileyen gizli bir değişken (örneğin enerji krizi) bu ilişkiyi yanıltıcı kılabilir. Double ML ve Causal Forest yöntemleri bu sorunu azaltmak için geliştirilmiştir.

Varsayım ve sınırlılık: Bu yöntemler, ölçülmeyen bir karıştırıcı olmadığını varsayar. Bu veri setinde benzin fiyatındaki farkların büyük kısmı ülkeler arasındadır (Çin, ABD, Hindistan düşük; Avrupa yüksek). Ülke ve marka modele eklendiğinde geriye kalan, ülke içindeki zamansal fiyat değişimidir ve bu değişim sınırlıdır. Bu durum, tahmin edilen etkilerin belirsizliğini artırmaktadır.

4.2 Yöntem: Double Machine Learning (LinearDML — Ortalama Nedensel Etki)

DML iki aşamada çalışır: (1) Hem Y hem de T, karıştırıcı değişkenler (X) üzerinden ayrı makine öğrenmesi modelleriyle (burada Random Forest, 5 katlı çapraz uydurma) tahmin edilir ve artıklar elde edilir. (2) Bu artıklar üzerinde regresyon kurularak karıştırıcıların etkisinden arındırılmış nedensel etki tahmin edilir.

LinearDML ortalama nedensel etki (ATE): -2,101 adet / +1 USD/L · %95 güven aralığı: [-49,083, +44,882]



Şekil 13. LinearDML ortalama nedensel etki ve %95 güven aralığı

Güven aralığı sıfırı geniş bir şekilde kapsamaktadır. Dolayısıyla karıştırıcılar kontrol edildikten sonra benzin fiyatının EV satışları üzerinde **istatistiksel olarak anlamlı bir ortalama etkisi bulunamamıştır**. Bu sonuç, etkinin olmadığını kanıtlamaz; veri setinin bu etkiyi ayırt etmek için yeterli bilgi içermediğini gösterir.

Düzeltilme notu: Raporun önceki sürümünde $\theta = -0.127$ olarak verilen değer, LinearDML'in ortalama etkisi değil, şarj altyapısının etkiyi nasıl değiştirdiğini gösteren katsayıdır (dml.coef_[0]). Ortalama etki dml.ate() fonksiyonu ile hesaplanmıştır.

4.3 Heterojen Etkiler: Causal Forest DML


Causal Forest, her gözlem (seri-ay) için ayrı bir nedensel etki (CATE, Conditional Average Treatment Effect) hesaplar. Böylece aynı benzin fiyatı artışının farklı pazarlarda farklı sonuçlar doğurup doğurmadığı incelenebilir.

Ölçü	Değer (adet / +1 USD/L)
Ortalama nedensel etki (ATE)	+3,794
ATE %95 güven aralığı	[-23,062, +30,651]
CATE standart sapması	11,961
En düşük CATE	-57,654
En yüksek CATE	+47,572
%90 güven aralığı sıfırı dışlayan gözlem oranı	%3.6

Tablo 12. Causal Forest DML özet sonuçları

Causal Forest'ın ortalama etkisi pozitif (+3,794) ancak güven aralığı yine sıfırı kapsamaktadır. Daha önemlisi, 420 gözlemin yalnızca **%3.6**'sında bireysel etkinin %90 güven aralığı sıfırı dışlamaktadır. Bu nedenle aşağıdaki alt grup karşılaştırmaları **eğilim** olarak okunmalı, kesin farklar olarak yorumlanmamalıdır.

4.3.1 Seri Bazında Nedensel Etki Analizi



Şekil 14. Seri bazında ortalama nedensel etki ve %90 güven aralıkları


Seri	Ortalama CATE	%90 GA alt	%90 GA üst
Çin – BYD	+9,745	-32,184	+51,674
Almanya – VW	+6,694	-3,805	+17,192
Norveç – BYD	+5,454	-3,349	+14,256
Fransa – Tümü	+3,480	-3,827	+10,787
Hollanda – Tümü	+3,337	-5,930	+12,604
Hindistan – Tümü	+3,163	-5,039	+11,366
ABD – Tesla	+2,690	-9,766	+15,146
İngiltere – Tümü	+1,689	-5,180	+8,557
Çin – Tesla	+141	-44,065	+44,348

Tablo 13. Seri bazında ortalama nedensel etki (adet / +1 USD/L)

Tüm serilerde ortalama etki pozitif yönde çıkmıştır; en yüksek değerler Çin – BYD (+9,745), Almanya – VW (+6,694) ve Norveç – BYD (+5,454) serilerinde, en düşük değer ise Çin – Tesla (+141) serisindedir. Ancak **hiçbir serinin güven aralığı sıfırı dışlamamaktadır** ve Çin serilerinin belirsizliği (± 40 bin adet civarı) diğerlerinden çok yüksektir. Bu nedenle ülkeler arasında "pozitif etkili" ve "negatif etkili" gruplar oluşturmak verilerle desteklenmemektedir.

Norveç ve Almanya serilerinin yalnızca tek bir markayı (BYD ve VW) kapsadığı da hatırlanmalıdır: bu sonuçlar ülkenin tüm EV pazarını değil, o markanın satışlarını yansıtır.


4.3.2 Yıl Bazında Nedensel Etki Analizi



Şekil 15. Yıl bazında ortalama nedensel etki

Ortalama etki 2019'da +1,695 iken 2021'de +9,437 ile en yüksek seviyeye çıkmış, 2022'de +3,846'e gerilemiş ve 2023'te -2,025 ile negatife dönmüştür. 2023'teki düşüş büyük ölçüde Çin serilerindeki negatif tahminlerden kaynaklanmaktadır (bkz. 5.2). Yıllık ortalamaların güven aralıklarının tamamı sıfırı kapsadığı için bu dalgalanma kesin bir zamansal trend olarak yorumlanmamalıdır; COVID sonrası teşvikler veya 2022 enerji krizi gibi açıklamalar ancak olası yorumlar olarak değerlendirilebilir.

4.3.3 Benzin Fiyatı Grubuna Göre Nedensel Etki Analizi



Şekil 16. Benzin fiyatı seviyesine göre nedensel etki

Grup	Aralık (\$/L)	Ortalama CATE	%90 GA	Ağırlıklı seriler
Düşük	0.47–1.06	+6,465	[–10,209, +23,140]	Hindistan, ABD, Çin
Orta-Düşük	1.06–1.31	+1,249	[–27,670, +30,169]	Çin (BYD, Tesla), Hindistan
Orta-Yüksek	1.31–1.73	+3,490	[–4,073, +11,052]	Fransa, İngiltere, Hollanda
Yüksek	1.73–2.38	+3,973	[–5,384, +13,329]	Hollanda, Norveç, Fransa

Tablo 14. Benzin fiyatı çeyrekliklerine göre nedensel etki

Benzin fiyatı gruplarının hepsinde ortalama etki pozitif çıkmış, en yüksek değer düşük fiyat grubunda görülmüştür. Ancak bu gruplar fiilen **ülke grupları** gibidir: düşük ve orta-düşük fiyat grupları Çin, ABD ve Hindistan'dan, yüksek fiyat grupları ise Avrupa ülkelerinden oluşmaktadır. Bu nedenle gruplar arasındaki fark, benzin fiyatının doğrusal olmayan etkisinden çok ülkeler arası farkları yansıtır olabilir. Tüm güven aralıkları sıfırı kapsadığından **benzin fiyatı ile EV satışları arasında doğrusal olmayan bir ilişki olduğu bu veriyle gösterilememektedir**.


4.4 Genel Bulguların Değerlendirilmesi

- LinearDML (–2,101) ve Causal Forest (+3,794) ortalama etkileri farklı yönlerde çıkmış, ikisinin de güven aralığı sıfırı geniş biçimde kapsamıştır. Dolayısıyla benzin fiyatı artışlarının EV satışlarını artırdığı ya da azalttığı söylenememektedir.
- Seri, yıl ve benzin fiyatı grubu bazındaki farklar istatistiksel olarak ayırt edilememektedir; heterojen etki analizinin sonuçları eğilim düzeyinde kalmaktadır.
- Bu sonuçların başlıca nedenleri: gözlem sayısının sınırlı olması (9 seri, 420 gözlem), satış verisinin çeyreklikten aylığa bölünmüş olması, benzin fiyatındaki değişimin büyük kısmının ülkeler arasında olması ve serilerin farklı kapsamlarda (ülke toplamı veya tek marka) olmasıdır.

5. Yorumlanabilir Nedensel Etki (Interpretable Causal Effect)

Bu bölümde "benzin fiyatının etkisini hangi değişkenler farklılaştırıyor?" sorusu incelenmektedir. Causal Forest'ın değişken önemi, standart makine öğrenmesi önem ölçüsünden farklıdır: satışı en iyi tahmin eden değişkeni değil, **benzin fiyatının etkisinin gözlemden gözleme neden değiştiğini** en iyi açıklayan değişkeni gösterir.

5.1 Causal Forest Değişken Önemi




Şekil 17. Causal Forest değişken önemi

Sıra	Değişken	Pay
1	Şarj Altyapısı	%43.9
2	Trend: BYD	%20.3
3	Ay	%6.7
4	Trend: electric car	%6.7
5	Ülke	%6.2
6	Trend: Tesla	%5.8
7	Marka	%5.7
8	Çeyrek	%2.5
9	Yıl	%2.1

Tablo 15. Etkinin farklılaşmasını açıklayan değişkenler

Etkinin farklılaşmasını en çok şarj altyapısı (%43.9) ve BYD arama trendi (%20.3) açıklamaktadır. Ancak bu iki değişken, ülkeyi ve markayı da büyük ölçüde temsil etmektedir (örneğin en yüksek şarj altyapısı ve BYD ilgisi Çin'dedir). Ayrıca 4.3'te görüldüğü gibi etki farklılıkları istatistiksel olarak anlamlı değildir. Dolayısıyla bu sıralama, "etki hangi değişkenlere göre ayrışıyor gibi görünüyor?" sorusuna bir **ipucu** verir, kesin bir politika öncelik sırası belirlemez.


5.2 Seri × Yıl CATE Isı Haritası



Şekil 18. Seri ve yıla göre nedensel etki (bin adet / +1 USD/L)

Çin serilerinde etki 2020–2021 döneminde yüksek pozitif (Çin – BYD: +20.9 ve +28.3 bin) iken 2023'te belirgin biçimde negatife dönmüştür (Çin – BYD: -18.9 bin, Çin – Tesla: -30.1 bin). Avrupa serileri, Hindistan ve ABD'de ise etki her yıl küçüktür ve ABD'nin 2022 değeri (-0.5 bin) dışında pozitif aralıktadır. Çin serilerinin güven aralıkları çok geniş olduğundan (5.2.2) bu değişim kesin değildir; Çin'deki hızlı pazar büyümesinin modelin benzin fiyatına attığı etkiyle karışmış olması olasıdır.

5.2.1 Şarj Altyapısı Seviyesine Göre Ortalama CATE




Şekil 19. Şarj altyapısı çeyrekliklerine göre nedensel etki

Altyapı seviyesi	Ortalama CATE	%90 GA	Ağırlıklı seriler
Q1 — Çok az	+2,707	[-4,668, +10,082]	Hindistan, İngiltere
Q2 — Az	+3,974	[-3,981, +11,930]	İngiltere, Fransa, Hollanda
Q3 — Orta	+3,208	[-6,566, +12,982]	Hollanda, ABD, Fransa
Q4 — Çok	+5,475	[-34,655, +45,605]	Çin (BYD, Tesla)

Tablo 16. Şarj altyapısı seviyesine göre nedensel etki

Ortalama etki altyapı seviyesi arttıkça genel olarak yükselmektedir (Q1: +2,707, Q4: +5,475). Ancak şarj altyapısı ile bireysel etki arasındaki doğrusal korelasyon $r = -0.27$, sıra korelasyonu (Spearman) ise 0.18 dir; yani ilişki zayıftır ve yönü ölçüye göre değişmektedir. Q4 grubunun tamamen Çin serilerinden oluşması ve güven aralığının çok geniş olması nedeniyle, "belirli bir altyapı eşiği aşıldığında benzin fiyatı etkili olmaya başlar" sonucu bu veriyle desteklenmemektedir.


5.2.2 Bireysel Nedensel Etkilerin Güven Aralıkları



Şekil 20. Rastgele 60 gözlem için bireysel nedensel etkiler ve %90 güven aralıkları

Grafikte her nokta bir seri-ay gözlemi için tahmin edilen etkiyi, dikey çizgiler ise %90 güven aralığını göstermektedir. Aralıkların büyük çoğunluğu sıfır çizgisini kesmektedir. Ortalama aralık genişliği İngiltere (13,737) ve Fransa (14,614) serilerinde en dar, Çin – BYD (83,858) ve Çin – Tesla (88,413) serilerinde en geniştir. Çin serilerinin hem çok büyük hem de hızla değişen satış hacmi, modelin bu serilerde güvenilir tahmin yapmasını zorlaştırmaktadır.

5.3 Şarj Altyapısı ve Tüketici İlgisi ile Nedensel Etki




Şekil 21. Şarj altyapısı (log ölçek) ve tüketici ilgisine göre bireysel nedensel etkiler

Sol grafikte şarj altyapısı logaritmik ölçekte gösterilmiş ve noktalar serilere göre renklendirilmiştir. Serilerin ayrı kümeler oluşturduğu ve şarj altyapısı ile etki arasındaki ilişkinin büyük ölçüde seriler arası farktan kaynaklandığı görülmektedir ($r = -0.27$). Sağ grafikte "electric car" arama trendi ile etki arasında belirgin bir ilişki bulunmamaktadır ($r = -0.09$).

5.4 Politika Simülasyonu: +0.30 \$/L Artış Senaryosu

Bu bölümde benzin fiyatının 0.30 USD/L artırılması (ortalama fiyata göre yaklaşık %22 artış) durumunda her seride aylık satışların nasıl değişebileceği, Causal Forest'ın tahmin ettiği etkiler kullanılarak hesaplanmıştır.



Şekil 22. Politika simülasyonu: benzin fiyatı +0.30 USD/L

Seri	Tahmini aylık etki	%90 GA	Ort. aylık satış
Çin – BYD	+2,923	[−9,655, +15,502]	264,489
Almanya – VW	+2,008	[−1,141, +5,158]	23,329
Norveç – BYD	+1,636	[−1,005, +4,277]	1,255
Fransa – Tümü	+1,044	[−1,148, +3,236]	23,198
Hollanda – Tümü	+1,001	[−1,779, +3,781]	7,610
Hindistan – Tümü	+949	[−1,512, +3,410]	2,676
ABD – Tesla	+807	[−2,930, +4,544]	89,316
İngiltere – Tümü	+507	[−1,554, +2,567]	23,448
Çin – Tesla	+42	[−13,220, +13,304]	47,322

Tablo 17. Politika simülasyonu sonuçları (adet / ay)

Tüm serilerde tahmini etki pozitif yönde çıkmakla birlikte **güven aralıklarının tamamı sıfırı kapsamaktadır**. Ayrıca model tüm serileri birlikte, adet cinsinden öğrendiği için küçük serilerde sonuçlar orantısız büyük çıkabilmektedir: örneğin Norveç – BYD için tahmin edilen +1,636 adet, bu serinin ortalama aylık satışını (1,255) aşmaktadır. Bu nedenle simülasyon sonuçları politika önerisi için değil, yöntemin nasıl uygulanabileceğini göstermek için kullanılmalıdır.

5.5 Sağlamlık Kontrolü: Logaritmik Satış Modeli

Serilerin satış hacimleri arasında 200 kattan fazla fark bulunduğundan (Norveç – BYD $\approx$ 1 bin, Çin – BYD $\approx$ 264 bin adet), adet cinsinden ortalama etki büyük serilere göre şekillenmektedir. Bu sorunu gidermek için aynı LinearDML modeli **logaritmik satış** ile yeniden kurulmuş ve etki yüzde değişim olarak ölçülmüştür.

Benzin fiyatındaki +0.10 USD/L artış $\rightarrow$ EV satışlarında ortalama %1.5 değişim $\cdot$ %95 güven aralığı: [%-3.5, %+6.7]

Yüzde ölçeğinde de etki pozitif yönde ancak istatistiksel olarak anlamsızdır. Bu sonuç, ana bulgunun (anlamlı bir ortalama etki bulunamaması) ölçek seçiminden bağımsız olduğunu göstermektedir. Gelecek

çalıřmalarda etkinin yüzde cinsinden ölçülmesi, farklı büyüklükteki pazarları karşılařtırmak için daha uygun olacaktır.

6. Genel Bulgular ve Tartıřma

6.1 Makine Öğrenmesi Bulgularının Deęerlendirilmesi

Zamana göre doğru bölünmüş test setinde en iyi makine öğrenmesi modeli Random Forest olmuřtur ($R^2 = 0.9655$). Ancak "geçen ayın satıřı" tahmini ($R^2 = 0.9675$) bu modelden daha iyi sonuç vermiřtir. Bu durum, aylık verinin çeyreklik deęerlerden türetilmiş olmasından kaynaklanmakta ve modellerin yüksek açıklama gücünün büyük ölçüde geçmiş satıřın tekrarı olduęunu göstermektedir. Raporun önceki sürümündeki daha yüksek skorlar, o ayın satıřını içeren rolling3 deęiřkeni (veri sızıntısı) ve zamana göre yapılmayan bölmeden etkilenmiřtir.

6.2 XAI ve SHAP Bulgularının Deęerlendirilmesi

SHAP analizi, tahminlerin geçmiş satıřlara dayandıęını, benzin fiyatının katkısının sınırlı ve negatif yönlü olduęunu göstermiřtir. Bu negatif iliřki, düşük benzin fiyatlı ölkelerdeki (Çin, ABD) serilerin hacminin yüksek olmasından kaynaklanmaktadır ve nedensel bir etki olarak yorumlanmamalıdır.

6.3 Nedensellik Analizi Bulgularının Deęerlendirilmesi

Double ML ve Causal Forest yöntemleri, karıřtırıcılar kontrol edildikten sonra benzin fiyatının EV satıřları üzerinde istatistiksel olarak anlamlı bir etkisini bulamamıřtır. Seri, yıl, benzin fiyatı seviyesi ve řarj altyapısı seviyesi bazında gözlenen farklar da güven aralıkları içinde kalmaktadır.

6.4 Türkiye İçin Çıkarımlar

Türkiye bu veri setinde yer almadıęından, Türkiye için doğrudan bir tahmin yapılamamaktadır. Bununla birlikte analiz sonuçları, yalnızca benzin fiyatı üzerinden yürütölecek bir politikanın EV dönüşümünü hızlandıracaęına dair güçlü bir kanıt sunmamaktadır. řarj altyapısı ve uygun fiyatlı EV eriřimi gibi faktörlerin rolü literatürde sıkça vurgulanmaktadır; ancak bu çalıřmanın verisi bu faktörlerin benzin fiyatı etkisini güçlendirdięini istatistiksel olarak doğrulamamaktadır. Türkiye için politika önerisi geliřtirmek, Türkiye'ye ait aylık satıř, řarj ve fiyat verisiyle ayrı bir analiz gerektirmektedir.

6.5 Çalıřmanın Sınırlılıkları

- **Veri yapısı:** Satıřlar çeyreklik ve yıllık raporlardan aylıęa bölünerek tahmin edilmiřtir (420 gözlemde 77 farklı deęer).
- **Seri kapsamı:** Dört ölkede ölkeler toplamı, dięerlerinde tek marka satıřı yer almaktadır; seriler doğrudan karşılaştırılabilir deęildir.
- **Gözlem sayısı:** 9 seri ve 420 gözlem, heterojen etkileri ayırt etmek için sınırlıdır.
- **Tedavi deęiřkeni:** Benzin fiyatındaki farkın büyük kısmı ölkeler arasındadır; ölkeler içi zamansal deęiřim sınırlıdır.
- **Ölçölmeýen karıřtırıcılar:** Teřvikler, vergi indirimleri, araç fiyatları ve gelir düzeyi gibi deęiřkenler veri setinde bulunmamaktadır.

6.6 Üç Katmanın Sentezi

Analiz katmanı	Temel bulgu	Katkısı
ML (tahmin)	Random Forest $R^2 = 0.965$; naif kıyas $R^2 = 0.968$	Tahminin geçmiş satışa dayandığı ortaya kondu
SHAP (açıklama)	Benzin fiyatı 6. sırada, katkısı sınırlı ve negatif yönlü	Modelin karar mekanizması açıklandı
LinearDML (nedensellik)	ATE = -2,101, GA sıfırı kapsıyor	Anlamli ortalama etki bulunamadı
Causal Forest (heterojen)	ATE = +3,794; gözlemlerin %3.6'sında anlamlı	Seri farkları eğilim düzeyinde kaldı
Log model (sağlamlık)	+0.10 \$/L → %1.5 (GA sıfırı kapsıyor)	Bulgu ölçekten bağımsız

Tablo 18. Üç analiz katmanının özeti

Üç katman birlikte değerlendirildiğinde, korelasyondan nedenselliğe geçişin önemi açıkça görülmektedir: ham korelasyon ve SHAP, benzin fiyatı ile satışlar arasında negatif bir ilişki gösterirken, karıştırıcılar kontrol edildiğinde bu ilişki ortadan kalkmakta ve anlamlı bir nedensel etki bulunamamaktadır.

6.7 Araştırma Sorusunun Yanıtı

"Bu veri setiyle benzin fiyatlarındaki artışın EV satışlarını anlamlı biçimde artırdığı veya azalttığı gösterilememiştir. Etkinin doğrusal olup olmadığı ve hangi koşullarda güçlendiği de istatistiksel olarak ayırt edilememektedir. Ham verideki negatif ilişki, ülkeler arası farklardan kaynaklanmaktadır."

7. Sonuç

Bu çalışma, benzin fiyatı ile elektrikli araç satışları arasındaki ilişkiyi üç analitik katman üzerinden incelemiştir. Makine öğrenmesi aşamasında, veri sızıntısı giderilip zamana göre doğru bölme yapıldığında modellerin geçmiş satışları tekrar etmenin ötesine geçemediği görülmüştür. SHAP analizi, benzin fiyatının modele katkısının sınırlı olduğunu ve görünen negatif ilişkinin ülkeler arası farklardan kaynaklandığını ortaya koymuştur. Double ML ve Causal Forest analizleri ise karıştırıcılar kontrol edildikten sonra benzin fiyatının EV satışları üzerinde istatistiksel olarak anlamlı bir etkisini bulamamıştır.

Çalışmanın en önemli bulgusu, **ham korelasyonun nedensellikle karıştırılmasının yanıltıcı sonuçlara yol açabileceğidir**. Aynı veri, korelasyon düzeyinde negatif bir ilişki gösterirken, nedensellik yöntemleri bu ilişkinin ülke farklarından kaynaklandığını ve tek başına benzin fiyatı üzerinden kesin bir sonuç çıkarılamayacağını göstermiştir.

Çalışmanın metodolojik katkısı, tahmin, açıklama ve nedensellik katmanlarını birlikte uygulayarak her birinin neyi söyleyip neyi söyleyemeyeceğini ortaya koymasındır. Gelecek çalışmalarda gerçek aylık satış verisi, ülke toplamı düzeyinde tutarlı seriler, daha fazla ülke ve teşvik ile araç fiyatı gibi ek karıştırıcılar kullanılarak benzin fiyatının etkisi daha güvenilir biçimde ölçülebilir.

Kullanılan Araçlar ve Kütüphaneler

Araç / Kütüphane	Kullanım amacı
Python, Google Colab	Geliştirme ortamı
pandas, numpy	Veri manipülasyonu
scikit-learn	Random Forest, metrikler
XGBoost, LightGBM	Gradient boosting modelleri
shap	SHAP değerleri ve görselleştirme
econml (Microsoft)	LinearDML, CausalForestDML
matplotlib, seaborn	Grafik ve görselleştirme

Tablo 19. Kullanılan araçlar

Kaynakça

Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C., Newey, W., & Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1–C68.

Athey, S., Tibshirani, J., & Wager, S. (2019). Generalized random forests. *The Annals of Statistics*, 47(2), 1148–1178.

Lundberg, S. M., & Lee, S. I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30.

EV Market Demand Forecast Dataset (EV Market Master). (2024). Kaggle. Lisans: CC BY 4.0. Kaynaklar: IEA Global EV Outlook 2024, Google Trends, BYD ve Tesla raporları, AFDC, GlobalPetrolPrices.

Kodlar: EV_sales_fuel_prices_duzeltilmis.ipynb [Colab bağlantısı eklenecek]